

Premiers jalons de la collation multilingue du *De Regimine Principum* latin et vernaculaire

Matthias Gille Levenson^{1, 4} Lucence Ing²

Carolina Macedo³

(1) Université Aix-Marseille

(2) ALMAAnaCH, Inria

(3) Biblissima+

(4) ENS de Lyon

4 juillet 2025

1. Introduction

Un projet de collation multilingue, à la croisée de la philologie et des méthodes computationnelles.

- Alignement et collation **semi-automatisés** sur textes médiévaux multilingues
- Présentation orientée **philologie** : variantes, transmission, traditions
- Quelques **éléments méthodologiques** seront évoqués pour éclairer le contexte

Lien vers les résultats :

https://prometext.github.io/Multilingual_Aegidius/

Enjeux de l'alignement multilingue : relier les traditions textuelles

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Conclusion

- Comprendre et reconstituer l'**histoire globale** d'une tradition textuelle
- Rapprocher des traditions textuelles souvent traitées séparément selon la langue ou la région
- Enrichir l'analyse d'une **tradition textuelle locale** en la confrontant à ses versions multilingues
- (Idéalement) apporter des informations manquantes dans une tradition à l'aide du texte d'une autre
- Traiter des corpus volumineux grâce aux outils numériques, malgré une **perte de précision** possible

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Conclusion

- Œuvre d'éducation princière
- Composée par **Gilles de Rome** autour de 1280 à destination du futur Philippe le Bel (r. 1285-1314)
- Diffusion de la **philosophie pratique aristotélicienne** (morale, économie, politique)
- Le texte de l'**imprimé romain de 1607** est **cité** de façon écrasante dans la littérature scientifique

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Conclusion

- Une **tradition latine foisonnante** (500+ manuscrits, 7 éditions tardomédiévales et modernes)
- **Traduit** dans une dizaine de langues
- Des traductions **directes** (castillan, catalan, anglais, français) et indirectes (la traduction italienne, *via* la traduction française de Gauchy)

Le corpus est choisi en fonction de la **disponibilité des numérisations**. Environ **350 pages** ont été acquises et analysées, soit un corpus de **17 témoins** latins, sur 7 chapitres.

- BNE Mss 9236 (fin xiv^e siècle)
- BNE MSS 958 (xv^e siècle)
- Valencia BH Ms 0594 (fin xiv^e siècle)
- Cambridge. Corpus Christi College, Parker Library MS 283 (xv^e siècle)
- Yale, Beinecke, Marston MS 139 (xiv^e siècle)
- BNF Lat. 6477 (xiv^e siècle)
- Genève, Ms. Lat. 92 (1460-1480)
- Mss Vat Lat 590 (fin xv^e siècle)
- Mss. Vat. Borgh. 360 (xiii^e siècle)
- Mss. Vat. Ross. 522 (xv^e siècle)
- Metz. Bibliothèque-médiathèque, 1234 (xiv^e siècle)
- 6 éditions imprimées (1473, 1482, 1498, 1502, 1556, 1607)

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Conclusion


Le corpus est choisi en fonction de la disponibilité des numérisations

- Un témoin anglais, issu de l'édition de FOWLER, BRIGGS et REMLEY 1997 (Bodleian Digby 233), début xv^e siècle
- Un témoin français : BNF Arsenal 5062 (1444)
- Un témoin castillan : Valladolid, Santa Cruz 251 (fin xiv^e siècle)
- Un témoin catalan : B. Catalunya 739 (1411)

2. Méthode

2.1 Méthode globale

Du manuscrit au corpus exploitable



2.2 Identifier les segments à aligner

La phrase, une notion anachronique

- Les outils de segmentation récents (comme LIU et ZHU 2023) reposent sur l'idée que les textes sont découpés en **phrases bien définies**, grâce à la ponctuation moderne.
- Or, dans les textes médiévaux :
 - la **ponctuation est présente**, mais son usage est **instable et non normé**,
 - elle ne marque pas forcément la fin d'une unité syntaxique,
 - la **majuscule initiale** n'est pas un indice fiable non plus.
- La notion de **phrase**, telle qu'on l'entend aujourd'hui, n'est donc **pas opératoire** pour la segmentation automatique de ces textes.

Détecter les débuts de segments avec BERT

Le modèle de segmentation utilise une approche d'apprentissage automatique (BERT) pour prédire automatiquement où commencent les segments syntaxiques.

Chaque mot (ou “token”) reçoit une étiquette :

- **0** = mot intérieur d'un segment
- **1** = début d'un nouveau segment

un	chemin	viés	et	ancien	si	ne	demora	gueses
0	0	0	0	0	1	0	0	0

Exemple de sortie du modèle : “si” marque le début d'un nouveau segment.

Un corpus multilingue d'entraînement pour la segmentation des textes anciens

Pour entraîner un modèle de segmentation automatique adapté aux textes médiévaux, il faut constituer un corpus de référence : riche, multilingue, et annoté à la main.

Objectifs :

- Délimiter les unités syntaxiques dans des textes médiévaux multilingues
- Fournir des données d'entraînement pour des modèles de segmentation automatique

M. Gille Levenson,
L. Ing, C. Macedo

Caractéristiques

- **Langues** : latin, français, castillan, portugais, catalan, italien, anglais
- **Volume** : 7 695 extraits ($\approx$ 50 000 segments annotés)
- **Annotation** : segmentation manuelle, syntaxique, non modernisante (£ = délimiteur)
- **Prétraitement** : nettoyage structurel (ponctuation, espaces), sans normalisation graphique
- **Heuristiques** : règles linguistiques propres à chaque langue
- **Sources** : éditions critiques, corpus spécialisés, transcriptions originales

Introduction

Méthode

Méthode globale

Identifier les segments à aligner

L'alignement

Résultats

Conclusion

2.3 L'alignement

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Méthode globale

Identifier les segments à aligner

L'alignement

Résultats

Conclusion

- L'alignement basé uniquement sur la forme (chaînes de caractères) est inefficace avec des textes traduits.
- Il faut recourir à une méthode **sémantique** de représentation du texte
- Nous utilisons des modèles multilingues pré-entraînés sur des paires de phrases parallèles : **LaBSE**.
- L'algorithme **Bertalign** (LIU et ZHU 2023) aligne des segments selon des relations $n \leq 1$ et $1 \leq n$.
- Une **phase d'amélioration** de l'alignement est en cours, avec un entraînement de modèle sur un corpus

Objectif Concevoir une ressource pour l'entraînement de modèles d'alignement automatique, adaptée aux textes anciens peu standardisés et aux divergences entre traditions textuelles (canon, ordre, contenu).

Caractéristiques

- **Type** : versets bibliques et coraniques, médiévaux et modernes
- **Langues** : 9 langues (latin, grec, français, castillan, catalan, italien, portugais, anglais, arabe)
- **Versions** : 29 témoins textuels, issus de corpus spécialisés et éditions critiques
- **Méthode** : alignement manuel ou semi-automatique, souvent à partir de la Vulgate
- **Volume** : plus de 48 000 versets alignés
- **Usage** : entraînement / évaluation de modèles NLP historiques • non adapté à l'édition critique

3. Résultats

3.1 Variantes latines significatives

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

- Tous les imprimés (sauf le premier incunable de 1473) se détachent des témoins manuscrits étudiés
- On identifie deux groupes d'imprimés, confirmés par leur histoire externe : 1482, 1498, 1502 face à 1556 et 1607.

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

- Un exemple paradigmatique en 2, 1, 24
 - Le titre du chapitre 2, 1, 24 est *Quomodo decet reges et principes et uniuersaliter omnes ciues propriis coniugibus sua aperire **secreta***. (leçon correcte)
 - L'ensemble de la tradition imprimée lit **consilia** : leçon fautive ou sens de secret ?
- Un second exemple en 2, 1, 14
 - *Regimen vero politicum est magis **parciale** [quam regimen regalem]* (leçon correcte).
 - Les imprimés lisent **paternale**, ainsi que Vat. Reg. Lat. 844.

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

- 2, 1, 15 : les manuscrits lisent *Unumquodque organorum optime perficiet suum opus si non multis operibus sit serviens, **sed uni.*** (leçon correcte)
- Les imprimés et Vat Lat 590 lisent : [...] *sit serviens **secundum naturam.***
- On retrouve difficilement d'autres variantes communes : il faudrait étendre le corpus

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

- Assez peu de regroupements concordants (tradition contaminée?) et des regroupements peu souvent complètement convaincants
- 1, 2, 2 : *Multo magis **hanc** duplicem potenciam natura dedit ipsis animalibus* (leçon correcte) contre *Multo magis **habent** ...* pour le groupe de témoins Beinecke + Cambridge + Vat Borgh + Ross + Reg Lat + Valence
- 3, 2, 1 : *Ut ad **philosophum** spectat* (Cambridge + Genève + Valence + Zainer + Ott Lat) face à *ut ad **propositum** spectat* (leçon correcte)
- 3, 3, 2 : *gentes nimis proprinque soli habundant sagacitate et industria sed deficiunt **strenuitate** et animositate* (BNF Lat 1234, leçon correcte), *impetu* (Rome 1607), *audacia* (Lille) face à *prudencia et animositate* (leçon majoritaire : Ott, Borgh, Vat Lat, Beinecke, Genève, Reg Lat, Ross, CCC) voire *providencia* (Valence)

3.2 Croisement avec l'alignement multilingue

M. Gille Levenson,
L. Ing, C. Macedo

2, 1, 15

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

5	9	Postquam ergo distinximus regimen coniugale a paternali,	Donques despuys que nos hauem departit lo regiment maïmonial del regiment paternal	Panne after, we hauen distyngwed	¶ pues que assi es despues que deprimos el gouernamiento mater moial del paternal	Dont apres que nous aouns distingue le regime coniugal dauec le paternel	postquam ergo distinximus regimen coniugale apaternali.	Postquod ergo distinximus regimen coniugale a paternali	Postquam ergo distinximus regimen coniugale a paternali.
6	10 11	quia paternale est magis totaliter et simpliciter, illud vero magis particulariter:	per tal con lo paternal es mes genaturalment e de tot entot soltament Mas aquell es mes particularment/	bytwene rewlynges coniugale, that is rewlyng ot wedloc, and paternale, that is fader rewlyng,	por que el paternal es mas general e mas segunt natura / · Et el otro es mas particular /-	en demonstrant	quia paternale est magis totaliter et simpliciter illud uero magis particulariter	quia paternale est magis totaliter et simpliciter id uero magis particulariter	quia paternale est magis totaliter et simpliciter. illud ueron magis peraticulariter.
7	12	et quia paternale est magis secundum naturam,	E per tal con lo paternal es mes natural segons natura	[for paternale] is more ful and hool rewlyng	Et por que el paternal es mas segunt natura	que le paternel est plus totalement et selon nature .	et secundum quid et quia paternale est magis	quia paternale est magis sensum naturam.	et quia paternale est magis scdm necam.
8	13	illud vero est quodammodo ex electione:	mas aquell en alguna manera es per elecio	and symple without condicioun, and the rewlyng nupcialis parcialis.	Mas el otro es en alguna manera por election /-	et laultre est plus particulierement et aucunement par election.	secundum regulam illud uero est quodammodo ex electione et rursus	Illud uero quodam modo est ex electione.	Illud uero quodam modo est ex electione l7 rursus

On relève la leçon particulière du BnF, Lat. 1234 *regulam* (contre *naturam*), reprise par l'anglais.

3, 2, 1

M. Gille Levenson,
L. Ing, C. Macedo

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

latin (Rome W)	français	castillan	anglais	Cambridge
videlicet de principatu, consilio, praetorio, et populo, breuiter (ut ad propositum spectat) dicemus in hac secunda parte huius tertii libri	nous parleron brièvement en ceste seconde partie du tiers liure ainsi que il appartient au propos. cest assavoir de principaulte de conseil. de pretoire. et du peuple.	conuiene desab del principado del conseio del alcallia del pueblo ediremos breuemente assi commo p tenesce al nuestro proponimiento en esta segunda parte deste tercero libro	ot conseile, ot geld hal, and of the puple, as it longeth to a filosofer, we schal schortlich speke in this ii partie ot this iii book ;	videlicet de principatu, consilio, praetorio, et populo, breuiter (ut ad philosophum spectat) dicemus in hac secunda parte huius tertii libri

Le témoin anglais propose la leçon *filosofer*, en suivant Cambridge, Genève, Valencia, Zainer, Ott (contre *propositum* / *populum* leçon fautive dans Lat. 1234

M. Gille Levenson,
L. Ing, C. Macedo

1, 2, 1

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

latin (Rome W)	français (Arsenal)	catalan	castillan	anglais	Genève
ex eo quod habeat di- gestiuam bonam, vel bonam augmen- tatiuam	pour auoir bonne nutritiue ou bonne augmen- tatiue.	per co com el ha bona digestio o bona crexença	por que muele bien la uianda nin por que cresce bi e se faze grande en el cuerpo	for he hath good deges- tioun and wexinge.	ex eo quod habeat augmen- tatiuam bonam, uel nutri- tiuam

Le français donne *nutritiue*, en accord avec Genève (*nutritiuam*, contre *digestiuam*, repris dans les autres témoins vernaculaires).

M. Gille Levenson,
L. Ing, C. Macedo

2, 1, 14

latin (Rome W)	français (Arsenal)	catalan	castillan	anglais	Genève
Sicut et Rex gentem sibi su- biectam regere debet se- cundum suum arbi- trium	Aussi comme le roy doit gouverner la gent a luy com- mise a son iugement et a sa uoulente	Axi con el Rey deu regir segons son enteni- ment la gent aell sotmes a	Et otssi el Rey deue gouernar la gente que es subiecta a el segunt su aluedo	and most spedfol for the child —as a kyng scholde rewle his men as hym se- meth	et regit si- cut et rex gentem sibi co- missam et su- biectam regere debet se- cundum suum arbi- trium

Le français donne *commise* en accord avec Genève (*comissam et subiectam*, contre *subiectam*, reprise dans les autres témoins vernaculaires).

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

D'autres rattachements possibles ?

1, 2, 2

latin (Rome w)	français	catalan	castillan	anglais	Beinecke
oportet ergo esse ratio- nalem poten- tiam, in qua po- test esse virtus.	Il co- nuient doncques que la puissance en quoy uertuz est mise soit racio- nele.	Coue donques que lapo- tencia en la qual ha esser la uirtut sia racio- nal	E por ende co- nuiene que sea poderio razonable aquel en que esta la uirtud	thanne the vertue moot be in the resonable vertue and po- tencial myght.	Oportet ergo esse ratio- nalem poten- tiam in qua ponitur esse uir- tus

Le français et le castillan suivent la leçon *ponitur* donnée par les manuscrits et Zainer tandis que le catalan et l'anglais introduisent des modaux.

M. Gille Levenson,
L. Ing, C. Macedo

3, 3, 2

Introduction

Méthode

Résultats

Variantes latines
significatives

Croisement avec
l'alignement multilingue

Conclusion

latin (Rome W)	français	catalan	castillan	anglais	Lat 1234	Beinecke
sed de- ficiunt im- petu et animo- sitate.	mais ilz def- faillent en cou- raige et en har- diesse.	Mas deffallen en pru- dencia o en sauiea e en co- ratge/	mas fallesçen en for- taleza e en bi- ueza de coraçon	and lacken bolde- nesse	sed de- ficiunt strenui- tate et animo- sitate	sed de- ficiunt pru- dentia et animo- sitate

Le **catalan** présente la **leçon fautive** avec la majorité des tém. mss lat. ; les autres témoins vernaculaires présentent des leçons minoritaires variées (et correctes).

4. Conclusion

- Conclusions **philologiques** :
 - Une **opposition** claire entre un **groupe d'imprimés** et un autre **groupe de manuscrits**, avec une **tradition imprimée** souvent fautive
 - La **difficulté** à **regrouper les témoins manuscrits** (biais de corpus ?)
 - Quelques **pistes** pour la tradition **multilingue**.
- Conclusions **méthodologiques** :
 - Une méthode via **acquisition automatique** permet de produire des tables de **collation exhaustives** et d'analyser l'**ensemble du corpus**
 - Elle se fait au **détriment de la précision du corpus** acquis et nécessite l'acceptation du bruit produit par les méthodes d'acquisition

Merci pour votre attention !

- ➡ **Code** : <https://github.com/prometext/aquilign>
- ➡ **Modèle BERT multilingue** : <https://huggingface.co/ProMeText/aquilign-multilingual-segmenter>
- ➡ **Corpus aligné** : https://github.com/ProMeText/Multilingual_Aegidius

Référence associée :

Lucence ING, Matthias GILLE LEVENSON et Jean-Baptiste CAMPS. « Textual Transmission without Borders : Multiple Multilingual Alignment and Stemmatology of the “Lancelot En Prose” (Medieval French, Castilian, Italian) ». In : CHR2024. Aarhus, Denmark, 2024

Biblissima⁺